

Ingeniería de soluciones con AI

Semestre 2026-2

Docente:
Francisco Macaya

Noticias: Yann LeCun, pionero en AI, reclama que los LLMs no son capaces de entender el mundo físico.

MAXWELL ZEFF

BUSINESS MAR 18, 2026 1:00 AM

Yann LeCun Raises \$1 Billion to Build AI That Understands the Physical World

Meta's former chief AI scientist has long argued that human-level AI will come from mastering the physical world, not language. His new startup, AMI, aims to prove it.



Noticias: World Models, la forma para entender el mundo.

Position: LLMs can't jump

Tom Zahavy¹

Abstract

How do we fundamentally discover new things? In a letter to Maurice Solovine, Albert Einstein conceptualized discovery as a cyclical process involving an intuitive 'jump' from sensory experience to axioms, followed by logical deduction. While Generative AI has mastered Induction (statistical pattern matching) and is rapidly conquering Deduction (formal proof), we argue it lacks the mechanism for Abduction—the generation of novel explanatory hypotheses. Using Einstein's formulation of General Relativity as a computational case study, we demonstrate that the prevail-




Figure 1. A generative AI reconstruction of Einstein's E-J-A diagram. Einstein drew this diagram in a letter to Maurice Solovine, showing a cyclical line jumping from Sense Experience (E) to Axioms (A) via a Jump (J), and then deducing logical consequences. Ironically, the hallucination of the axiomatic symbols highlights the very difficulty of automating the jump.

To build an AI capable of true invention, we must therefore move beyond systems that merely read scientific literature to systems that can perceive the physical world. The emergence of physically consistent World Models offers a pathway to a synthetic laboratory. By enabling agents to run counterfactual simulations—to experience the physical consequences of a thought experiment—we may finally mechanize the feedback loop between intuition and logic.

Finally, we emphasize that this proposal is specifically tailored to the physical sciences, where the object of study is external material reality. In abstract domains such as Mathematics or Computer Science, the Sense Experience (E) may be grounded in high-dimensional topology or have other goals such as generality or minimality. While the necessity of the Abductive Jump remains universal, the nature of the simulation must be adapted to the ontology of the discipline: for physics, the substrate is the world; for mathematics, it is the abstract landscape of formal systems.

Noticias: DashAI, la plataforma chilena de AI.



UNIVERSIDAD DE CHILE

Facultades ▾ U-Cursos MI Uchile Correo en fr pt Buscar en uchile.cl

Postulantes Estudiantes Académicos/os Funcionarios/os Egresados/os

ADMISIÓN CARRERAS POSTGRADOS INVESTIGACIÓN EXTENSIÓN BIBLIOTECAS LA UNIVERSIDAD

Inicio > Noticias

NOTICIAS

MÁS NOTICIAS

u de Chile lidera becas Chile de doctorado en el extranjero 2026

Congreso IEI 2026: La inter y transdisciplina se reúnen en la UChile

Inteligencia artificial:

U. de Chile presentó dashAI, plataforma chilena que permite trabajar sin entregar datos

La Facultad de Ciencias Físicas y Matemáticas de la Universidad de Chile, a través de su Iniciativa de Datos e Inteligencia Artificial (IDIA), lanzó un software libre y gratuito que permite entrenar modelos de inteligencia artificial sin necesidad de saber programar. La herramienta opera de forma 100% local en el computador del usuario/a, sin dependencias obligatorias de la nube, posicionando a la institución a la vanguardia del desarrollo tecnológico público



Clase 1.2: Técnicas de Prompt Engineering

Se cubrirán los siguientes tópicos en la clase:

- Zero-shot.
- Few-shot learning.
- Chain-of-thought.
- Prompts Especializados.

No obstante, esta clase *no cubrirá* los siguientes tópicos:

- fine-tuning.
- RAG.


Reminder: Que hemos visto hasta ahora...

Los LLMs tiene una estructura de mensajes:

- Prompt de Sistema**
- Human Message**
- Asistent Message**

Los LLMs tiene una parámetros de entrada

- Tempuratura
- Max token



Los LLMs entregan los siguiente output:

- Texto generado (response/completion)
- Usage_prompt (Prompt, completion and total tokens)
- Finished reason.

Reminder: Que hemos visto hasta ahora...


Prompt Engineering: Estructurar la llamada.

Los LLMs tienen una estructura de mensajes, compuesta por:

- Prompt de sistema
- Human message
- Assistant message

Los LLMs tienen parámetros de entrada, entre los que se encuentran:

- Temperatura
- Max tokens



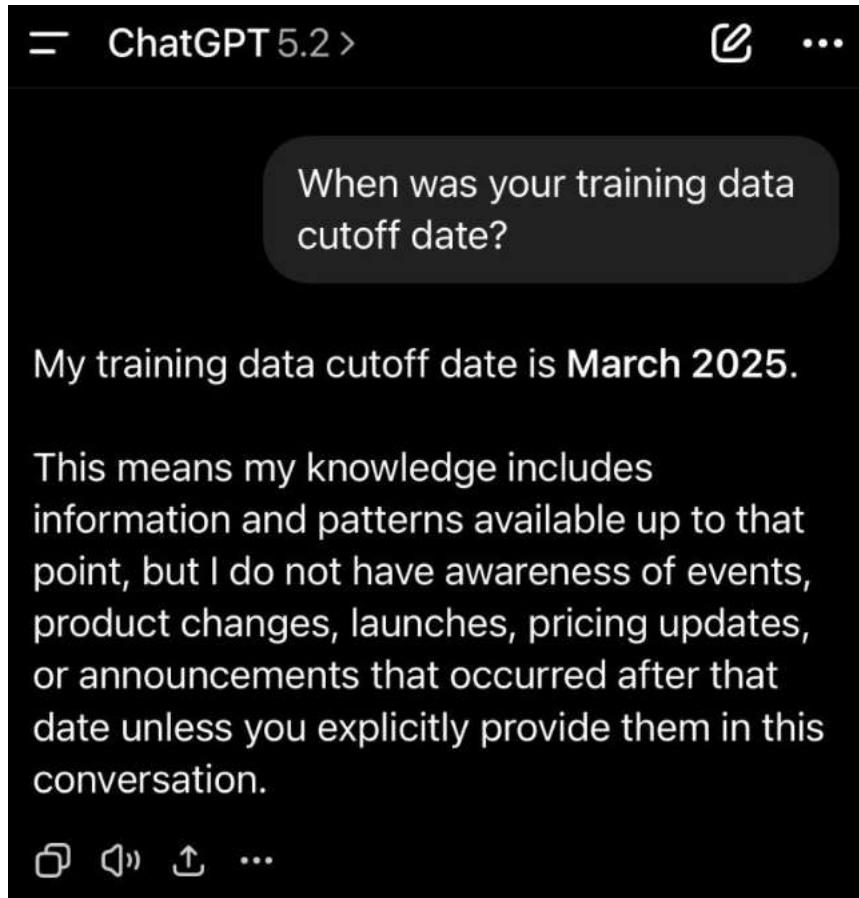
LLMs

Los LLMs entregan los siguientes outputs:

- 1-) Texto generado (response/completion)
 - 2)- Usage prompt: incluye prompt tokens, completion tokens y total tokens.
- Finish reason: indica la razón por la cual el modelo terminó de generar la respuesta.

Los proveedores más conocidos de LLMs son **Meta, OpenAI, Anthropic, Google**

Why: ¿Por qué los LLMs no me responden como quiero?



Los modelos de lenguaje son entrenados con toda la información del internet, y tiene una fecha de corte de entrenamiento (“cut-off”).

- Los LLMs son generalistas.
- Tienen una fecha de corte.
- Se construyen en base a datos públicos, no privados.

Hay técnicas para resolver estos *problemas*.

Hallucinate: El talón de Aquiles de los LLMs.

Why Language Models Hallucinate

Adam Tauman Kalai*
OpenAI

Ofir Nachum
OpenAI

Santosh S. Vempala†
Georgia Tech

Edwin Zhang
OpenAI

September 4, 2025

Abstract


Like students facing hard exam questions, large language models sometimes guess when uncertain, producing plausible yet incorrect statements instead of admitting uncertainty. Such “hallucinations” persist even in state-of-the-art systems and undermine trust. We argue that language models hallucinate because the training and evaluation procedures reward guessing over acknowledging uncertainty, and we analyze the statistical causes of hallucinations in the modern training pipeline. Hallucinations need not be mysterious—they originate simply as errors in binary classification. If incorrect statements cannot be distinguished from facts, then hallucinations in pretrained language models will arise through natural statistical pressures. We then argue that hallucinations persist due to the way most evaluations are graded—language models are optimized to be good test-takers, and guessing when uncertain improves test performance. This “epidemic” of penalizing uncertain responses can only be addressed through a socio-technical mitigation: modifying the scoring of existing benchmarks that are misaligned but dominate leaderboards, rather than introducing additional hallucination evaluations. This change may steer the field toward more trustworthy AI systems.

Las alucinaciones son originadas como errores en la clasificación binaria durante el entrenamiento de los modelos. Si las declaraciones incorrectas no son distinguidas de los hechos, entonces las alucinaciones de los modelos son perpetuadas a través del proceso de entrenamiento.

Mucho LLMs son optimizados para ser buenos testadores, y adivinar, lo que mejora el rendimiento de las métricas de tests.

v1 [cs.CL] 4 Sep 2025

O'REILLY: AI Engineering




“Anyone can communicate, but not everyone can communicate effectively”.

Prompt engineering refers to methods for writing and organizing LLM instructions for optimal outcomes

Context engineering refers to the set of strategies for curating and maintaining the optimal set of tokens (information) during LLM inference, including all the other information that may land there outside of the prompts.

*Los **conceptos** se comprenden mejor en una imagen.*



- (1) **La compactación** mantiene el flujo de la conversación en tareas que requieren una interacción extensa de ida y vuelta.
- (2) **La toma de notas** destaca en el desarrollo iterativo con hitos claramente definidos.
- (3) **Las arquitecturas multiagente** gestionan investigaciones y análisis complejos en los que la exploración en paralelo aporta beneficios.

Tipos de comunicaciones: Sistema, humano y asistente.

```
messages =
```

```
[
```

```
  system
```

```
  user
```

```
  assistant
```

```
  user
```

```
  assistant
```

```
  ...
```

```
]
```

→ **Prompt System:** define el comportamiento del modelo.

→ **User Message:** mensaje del usuario.

→ **Assistant Message:** respuesta del modelo de lenguaje.
Si existe una conversación, cada interacción se debe almacenar para entregarla como parámetro al request.

Las técnicas de **Prompt Engineering** buscan personalizar y ajustar el Prompt System, no los demás mensajes.

¿Cuáles son las técnicas de Prompt Engineering?

Zero – Shot Prompting

Mensaje directo al LLM, sin ningún ejemplo previo.

Ventajas:

- Implementación fácil y rápida.

Desventajas:

- Poco confiable.
- Los problemas reales son complejos, entonces muy poco usado en la industria.

Instrucción clara + Contexto → Resultado esperado

"Clasifica el siguiente email como spam o no spam: [email]"

Few-Shot Prompting

Mensaje directo al LLM, pero con ejemplos de entradas y salidas. Le doy ejemplos al LLM de como quiero que trabaje.

Ventajas:

- Mas preciso en la tarea. Le enseño como comportarse.

Desventajas:

- Output más estándar.
- Necesito tener los ejemplos.
- El prompt puede tomar más tiempo en construirlo.

Ejemplos + Patrón + Nueva entrada → Resultado

Ejemplo 1: Input → Output

Ejemplo 2: Input → Output

Nueva entrada: [input] → ?

Chain-of-Thought (COF)

Antes de tener una respuesta, lo correcto es “pensar”. El COF busca que los LLMs construyan una secuencia de pasos antes de entregar la respuesta, como si estuvieran haciendo el calculo matemático de una expresión compleja en “Voz Alta”.

Ventajas:

- Mayor confiabilidad.
- Trazabilidad del pensamiento respecto a la respuesta dada.
- Descompone, razona y construye la respuesta.
- Debugging.

Desventajas:


- Toma mayor tiempo de inferencia.
- No aplica para todos los casos.

Problema + "Piensa paso a paso" → Razonamiento + Solución
"Resuelve: 23×17 . Piensa paso a paso."

Técnicas avanzadas de Prompting

Tree of Thoughts (ToT) Self-Consistency

Tree of Thoughts permite al modelo explorar múltiples caminos de razonamiento de manera sistemática, evaluando y seleccionando las mejores opciones.



Self-Consistency mejora la confiabilidad generando múltiples respuestas y seleccionando la más consistente.

Program-Aided Language Models (PAL)

PAL combina el **razonamiento de LLMs con la precisión** de código ejecutable para cálculos exactos. Se utiliza para cálculos numéricos más complejos, que necesitan una secuencia de etapas.

Meta-Prompting

Meta-prompting usa el LLM para generar y optimizar prompts para tareas específicas.

Prompt Chaining

Prompt chaining conecta múltiples prompts en secuencia, donde la salida de uno alimenta al siguiente

¿Cómo construir un buen prompt?

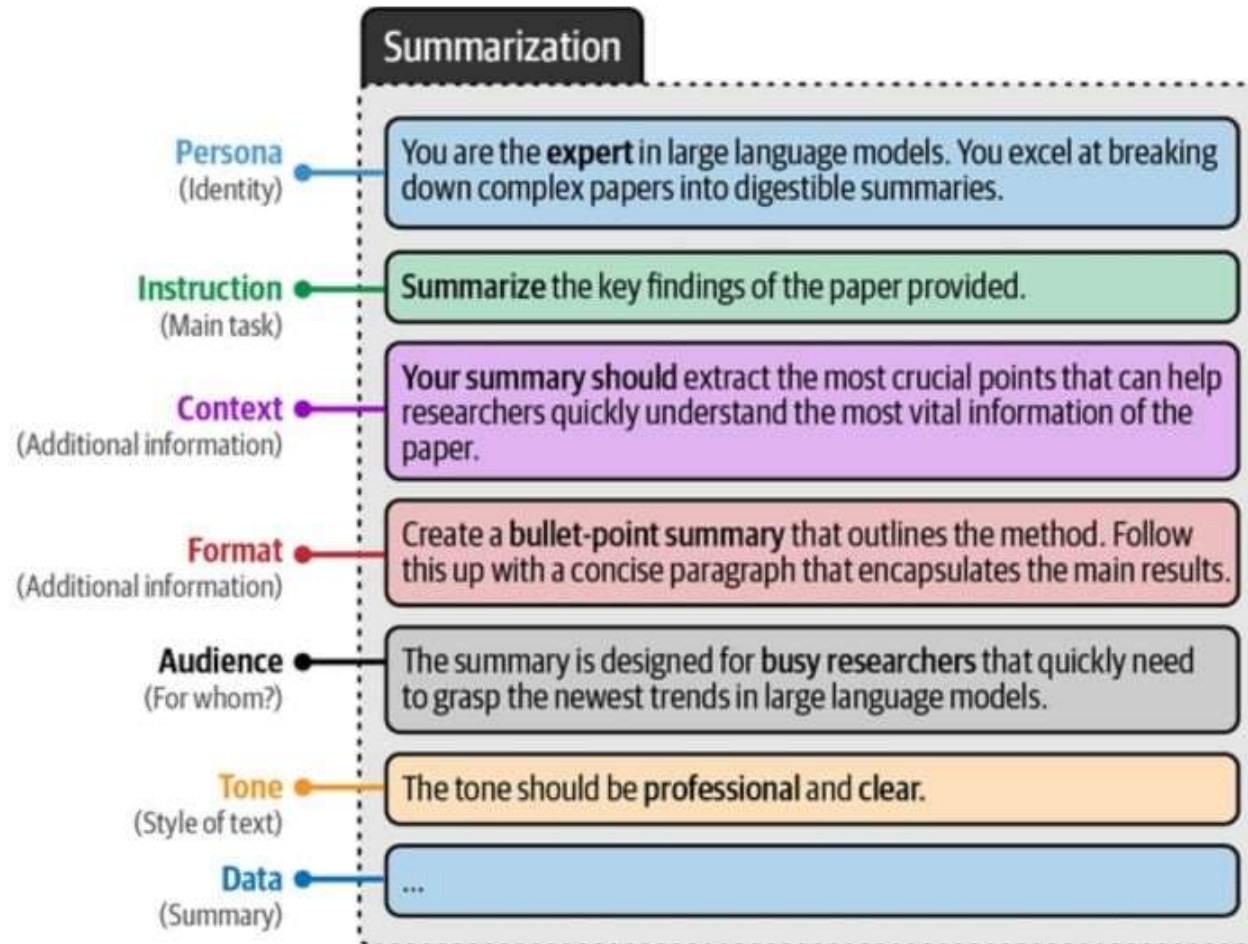
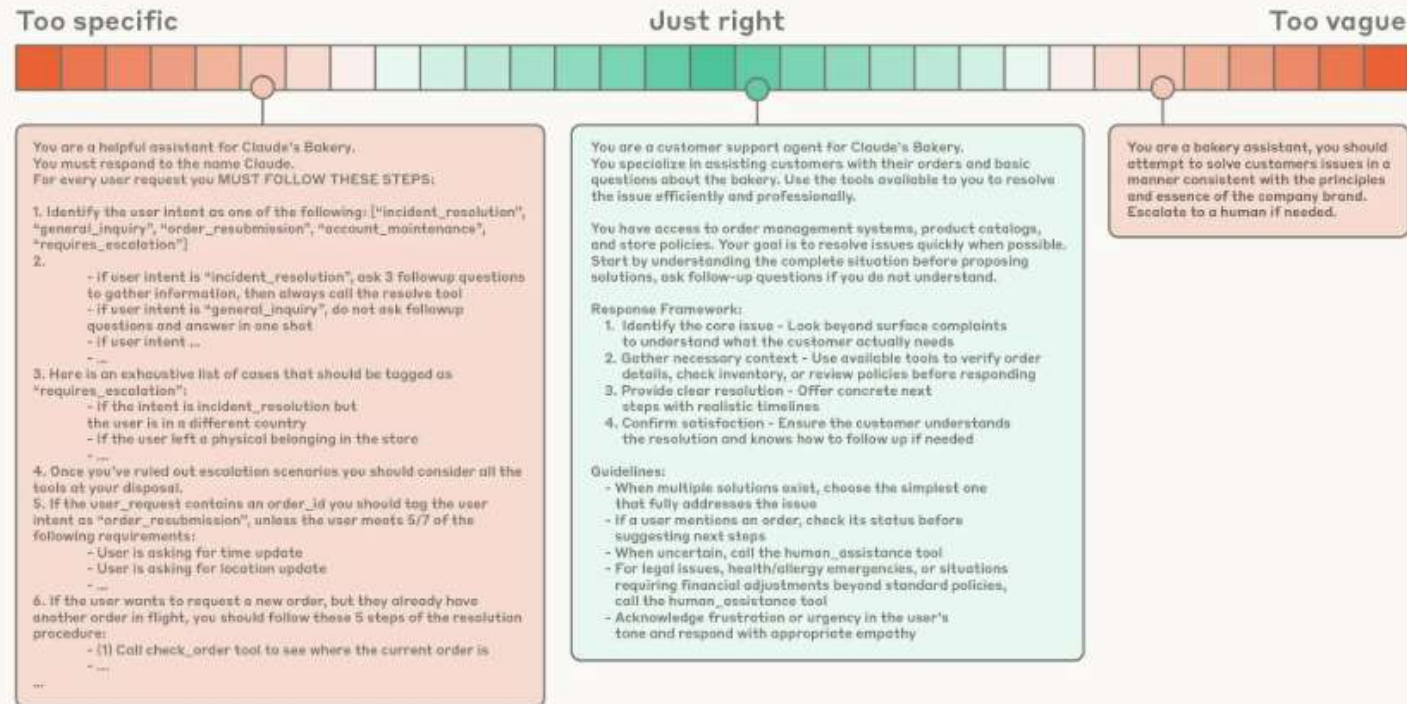


Figure 6-11. An example of a complex prompt with many components.

Simplicity is the ultimate sophistication. (Leonardo da Vinci)


¿Cómo luce un buen prompt?

Calibrating the system prompt




Simplicity is the ultimate sophistication. (Leonardo da Vinci)

Idea: ¿Qué construir?



Cementerios de Startup: <https://startups.rip/>



- **Wholesome (actividades sanas):** No uses IA. Disfrútalas.
- **Toxic (actividades tóxicas):** Usa IA para automatizarlas o eliminarlas. No queremos lidiar con ellas.
- **Chores (tareas domésticas o rutinarias):** Usa IA para hacerlas más placenteras. (Sigam pensando.)
- **Vices (vicios):** Usa IA para evitar hacerlas.