

Ingeniería de soluciones con AI

Semestre 2026-2

Docente:
Francisco Macaya

El investigador de Anthropic que renunció por temor a la IA habla con WIRED: “Los próximos dos años decidirán el destino de la humanidad”

Jacob Coxon habla con WIRED sobre el “mini Proyecto Manhattan” que se está llevando a cabo en Anthropic, el problema de la alineación y por qué a los laboratorios de IA solo les quedan unos pocos años para conseguir que sus sistemas sean seguros.



WIRED: ¿Podrías explicarme la diferencia entre el problema de la alineación?

También algo que dijiste en tu publicación en X: a saber, que “las personas que desarrollan la IA creen sinceramente que podría matarnos a todos antes de que termine la década”. No creo que todo el mundo entienda cómo se relacionan ambas cosas.

JC: El principal obstáculo para entender esto es lo dicho: que suena a ciencia ficción. Pero es bastante importante que todos los que escriben ciencia ficción sobre la IA lleguen a la conclusión de que existe un gran riesgo de que algo mucho más inteligente pueda, en cierto modo, tomar el control. Lo tenemos como un tropo, pero hay una parte de verdad evidente en ello.

Imagina que te enfrentas a un mono. La IA tiene con respecto al ser humano la misma diferencia de inteligencia que nosotros tenemos con respecto a un mono. Eso, en mi opinión, supone una diferencia intelectual bastante extrema.

Y ahora, imagina que tenemos que controlar el comportamiento de esta entidad infinitamente más inteligente, lo cual plantea el problema de la alineación: garantizar que haga exactamente lo que queremos. Es bastante difícil que un mono controle a un humano, por poner una simple analogía. Tenemos que tener mucho cuidado de abordar el problema del control de forma totalmente acertada.

Cuando hablamos de la extinción de la humanidad, es porque, para algo tan inteligente, le resultará realmente muy sencillo acabar con todo el mundo. Imagina que la IA decide que no quiere que la apaguen, lo cual me parece algo bastante natural, ¿verdad? Por la razón que sea, decide que no quiere acabarse. Y se da cuenta de que los humanos la van a apagar mañana. Entonces, ¿cómo impide que los humanos la apaguen? Quizá se le ocurra alguna forma ingeniosa; si es lo suficientemente inteligente, podría aniquilar a la humanidad para que no la apaguen.

Nota: <https://www-cdn.anthropic.com/08ab9158070959f88f296514c21b7facce6f52bc.pdf>

PISA 2025: Chile retrocede en matemáticas y lectura tras una década de caída sostenida en el Informe PISA.



Nota: <https://www.youtube.com/watch?v=fNLBeGyTNf8>

Feedback de la Evaluación 1: Pros y contra.

Pros

- En general, buen formato del informe.
- La mayoría cumplió con la arquitectura RAG, desde la ingesta, retrieval y generación.
- Trabajo en tiempo.
- Proyectos interesantes, tales como: ContigoAI y Agente Auditor Comunitario.
- La mayoría organizó bien el código, dividiéndolo por cada parte del problema.

Contra

- Mediocre análisis cuantitativo de la solución. En general, la mayoría de los trabajos no construyó un dataset para evaluar y medir la solución.
Idea: Usar AI para generar cientos de ejemplos.
- Datos tabulares tienen más sentido usar Text-to-SQL.
- Nunca entregar un jupyter como código.
- No olvidar entregar el repositorio cuando suban el trabajo.
- Pocos se cuestionan qué pasa si hay cambios en los datos. Si se actualiza la información, ¿cómo mi sistema se adapta?
- Código siempre en **INGLÉS**.

Feedback de la Evaluación 1: Pros y contra.

Pros

- En general, buen formato del informe.
- La mayoría cumplió con la arquitectura RAG, desde la ingesta, retrieval y generación.
- Trabajo en tiempo.
- Proyectos interesantes, tales como: ContigoAI y Agente Auditor Comunitario.
- La mayoría organizó bien el código, dividiéndolo por cada parte del problema.

Contra

- Mediocre análisis cuantitativo de la solución. En general, la mayoría de los trabajos no construyó un dataset para evaluar y medir la solución.
Idea: Usar AI para generar cientos de ejemplos.
- Datos tabulares tienen más sentido usar Text-to-SQL.
- Nunca entregar un jupyter como código.
- No olvidar entregar el repositorio cuando suban el trabajo.
- Pocos se cuestionan qué pasa si hay cambios en los datos. Si se actualiza la información, ¿como mi sistema se adapta?
- Código siempre en **INGLÉS**.

Solución: CRED-SQL: Enhancing Real-world Large Scale Database Text-to-SQL Parsing through Cluster Retrieval and Execution Description.

CRED-SQL: Enhancing Real-world Large Scale Database Text-to-SQL Parsing through Cluster Retrieval and Execution Description

Shaoming Duan^{a,b,1}, Zirui Wang^{a,1}, Chuanyi Liu^{a,b,*}, Zhibin Zhu^a, Yuhao Zhang^{a,c}, Peiyi Han^{a,b}, Liang Yan^{a,d} and Zewu Peng^c

^aHarbin Institute of Technology, Shenzhen, China

^bPengcheng Laboratory, Shenzhen, China

^cMindflow.ai

^dInspur Cloud Information Technology Co., Ltd, Jinan 250101, China

^eGuangdong Power Grid Co., Ltd, China

Abstract. Recent advances in large language models (LLMs) have significantly improved the accuracy of Text-to-SQL systems. However, a critical challenge remains: the semantic mismatch between natural language questions (NLQs) and their corresponding SQL queries. This issue is exacerbated in large-scale databases, where semantically similar attributes hinder schema linking and semantic drift during SQL generation, ultimately reducing model accuracy. To address these challenges, we introduce CRED-SQL, a framework designed for large-scale databases that integrates Cluster Retrieval and Execution Description. CRED-SQL first performs cluster-based

Question: Which cities do more than one employee under age 30 come from? Gold Table: employee, hire_evaluation, employee Gold SQL: SELECT city FROM employee WHERE age < 30 GROUP BY city HAVING count(*) > 1	
CRUSH [11] TOP-10 Tables: "city_record.city", "company_employee.people", "course_teach_teacher.Age", "store_1.employees", "customer_deliveries.Employees", "company_employee.people", "activity_1.Student", "employee_hire_evaluation.evaluation", "crew_Doc_Control_Systems.Employees", "voter_2.Student"	Our CRED-SQL TOP-10 Tables: "company_employee.company", "company_1.employee", "employee_hire_evaluation.employee", "company_employee.people", "company_employee.employment", "right_1.employee", "store_1.employees", "company_office_office.locations", "company_1.works_on", "college_1.EMPLOYEE"

Schema Mismatch: The target table is not in the Top 10 list of searches

CLJ 20 Aug 2025

Dataset card
Data Studio
Files and versions
Community

Dataset Viewer
Auto-converted to Parquet
API
Embed
Duplicate
Data Studio

Split (2)
train · 7k rows

Search this dataset

db_id	query	question	query_toks	query_toks_no_v
string · classes	string · lengths	string · lengths	sequence · lengths	sequence · lengths
148 values	18	16	4	4
department_management	SELECT count(*) FROM head WHERE age > 56	How many heads of the departments are older than...	["SELECT", "count", "(", "*", ")", "FROM", "head", "..."]	["select", "co", "sequence", "long"]
department_management	SELECT name, born_state, age FROM head ORDER BY age	List the name, born state and age of the heads of...	["SELECT", "name", ",", "born_state", ",", "age", "..."]	["select", "na", "born_state", "]"]
department_management	SELECT creation, name, budget_in_billions FROM	List the creation year, name and budget of each.	["SELECT", "creation", ",", "name", ",", "budget_in_billions", "..."]	["select", "cr", "name", ""]
department_management	SELECT max(budget_in_billions) FROM	What are the maximum and minimum budget of the.	["SELECT", "max", "(", "budget_in_billions", ")", "..."]	["select", "na", "budget_in_bill"]
department_management	SELECT avg(num_employees) FROM department WHERE rankin...	What is the average number of employees of the.	["SELECT", "avg", "(", "num_employees", ")", "..."]	["select", "av", "num_employees"]
department_management	SELECT name FROM head WHERE	What are the names of the	["SELECT", "name", "..."]	["select", "na"]

(Previous 1 2 3 ... 78 Next)

→ Copy to bucket
→ Use this dataset

Downloads last month 14,286

Homepages: yale-ily.github.io
Repository: github.com
Paper: acweb.org

Paper: arxiv.org
Point of Contact: Yale LILY
Number of rows: 8,034

Total file size: 964 KB

Models trained or fine-tuned on xlangai/spider

jondutrin/bagel-dpo-34b-v0.2
Text Generation · 34B · Updated... 8.57K · 97

mademacher/mpt-30b-instruct-11-GGUF
30B · Updated Dec 18, 2024 · 3.87K

Nota: <https://arxiv.org/pdf/2508.12769v1>


Nota: <https://huggingface.co/datasets/xlangai/spider> **Nota :** <https://huggingface.co/datasets/HAL-9001/spider-databases>

¿Qué es la memoria?


“Lo que te hace tú no es tu cuerpo — sino que recuerdas haber sido tú antes.”

John Locke (1689)

Memoria : Tipos de memoria en el humano.



Memoria : Tipo de memoria en los agentes.



Short-term memory: Es todo lo que el agente puede "ver" y recordar en este momento — su ventana de atención activa.

Long-term memory: Es todo lo que el agente puede recordar más allá de su context window — información persistente que sobrevive entre sesiones.


LangChain: Técnicas avanzadas de memoria.

Memory Type	What is Stored	Human Example	Agent Example
<u>Semantic</u>	Facts	Things I learned in school	Facts about a user
<u>Episodic</u>	Experiences	Things I did	Past agent actions
<u>Procedural</u>	Instructions	Instincts or motor skills	Agent system prompt

*La memoria también puede clasificarse según el tipo de conocimiento que almacena, tomando como base la ciencia cognitiva. Se distingue la **semántica**, **episódica** y **procedimental**.*


Semántica: Tu perfil.

Los recuerdos semánticos pueden gestionarse de distintas maneras. Por ejemplo, los recuerdos pueden consistir en un único "perfil" continuamente actualizado con información bien definida y específica sobre un usuario, organización u otra entidad (incluido el propio agente).



Episódica: Acciones o episodios pasadas.

La memoria episódica, tanto en humanos como en agentes de IA, implica recordar eventos o acciones pasadas. El artículo CoALA lo plantea de forma clara: los hechos pueden escribirse en la memoria semántica, mientras que las experiencias pueden escribirse en la memoria episódica. En el caso de los agentes de IA, la memoria episódica se utiliza frecuentemente para ayudar al agente a recordar cómo llevar a cabo una tarea.




Name	Most Recent Run	Trace Count	Error Rate	P50 Latency	P99 Latency	Description
rag-duoc-uc		0	0%			
redmine		0	0%			
project_reminders		0	0%			
reminder		0	0%			
arithmetic		0	0%			

No datasets found
Start by creating a new dataset to run experiments
[New Dataset](#)


Procedural: Ejecutar acciones o habilidades.

Son las reglas utilizadas para realizar tareas. En los humanos, la memoria procedimental es como el conocimiento interiorizado de cómo ejecutar acciones, como montar en bicicleta mediante habilidades motoras básicas y equilibrio. La memoria episódica, en cambio, implica recordar experiencias específicas, como la primera vez que se montó en bicicleta sin ruedines o un paseo memorable por una ruta pintoresca. En el caso de los agentes de IA, la memoria procedimental es una combinación de los pesos del modelo, el código del agente y el prompt del agente, que en conjunto determinan la funcionalidad del agente.



The Forgetting Problem: ¿Qué recordar?

Andrej Karpathy: “One common issue with personalization in all LLMs: a casual question from two months ago gets permanently treated as a deep interest and keeps resurfacing.” The real problem isn’t remembering - it’s knowing what to forget”.



Nota: Andrej Karpathy, who co-founded and formerly worked at OpenAI

Arquitecturas de memoria: Flat hasta grafos.

La memoria puede ser almacenada como:

1. Base de datos vectorial (Vector Database)
2. Sistema de archivos (File System)
3. Contexto (Context Window)
4. Base de datos de grafos (Graph Database).


Product	Company / Founder	Stars	Funding	Architecture	Backend	LongMemEval
Mem0	Deshraj Yadav (YC)	50K	\$24M Series A	Vector + Graph	20+ backends + Neo4j	49%
Graphiti/Zep	Zep AI	24K	–	Temporal KG	Neo4j	71.2%
Letta/MemGPT	UC Berkeley	22K	\$10M	LLM-as-OS	SQLite/PG	–
OpenViking	ByteDance/Volcengine	19K	Internal	Context DB	Volcengine	–
Supermemory	Dhravya Shah (age 19)	17K	\$2.6M Seed	Atomic facts + relations	Cloudflare KV	85.2%
Cognee	Cognee AI	13K	\$7.5M	ECL + Memify	LanceDB + Kuzu	–
Memori	GibsonAI (Bobur U.)	12K	–	Pure SQL	PG/SQLite	–
Knowledge	Knowledge Labs	108	–	Local personal KG	Local + MCP	–
Hindsight		6.4K	–	4-net + 4-way retrieval	Graph + Vector + BM25	91.4%
HydraDB	HydraDB Inc	Closed	\$6.5M	Git-style append KG	Custom graph + vector	90.8%
MemOS	MemTensor (SJTU/IAAR)	7.9K	–	Memory OS	Qdrant + Neo4j	75.8%
mem9	PingCAP (Ed Huang)	751	–	Stateless plugin	TiDB	–
Platform Built-in Memory						
ChatGPT	OpenAI	–	–	User facts + history retrieval	Closed source	–
Claude.ai	Anthropic	–	–	Project Knowledge Base	Closed source	–
Claude Code	Anthropic	–	–	CLAUDE.md + MEMORY.md	File system	–
Codex	OpenAI	–	–	File system + sandbox	File system	–

Una mirada a nivel de producto.

A nivel de producto, el memoria puede ser catalogada en dos ejes:

1. Structured Graph vs Flat Storage

2. Active Managment or Passive Store.



Agentes más que solo LLMs.


Memoria

mecanismos que permiten a un modelo retener y utilizar información.

La memoria no es solo un accesorio en los agentes, es parte fundamental para su auto evolución

Plan

Capacidad del modelo de descomponer un problema en tareas para resolverlo.



LLMs

El motor del modelo. Los principales proveedor son OpenAI, Google y Anthropic

Tools

Funciones que le permiten al modelo conectarse con el mundo exterior.

Memoria: Desde raw hasta comportamiento

Etapa 1

El agente tiene casos anteriores de cómo definió un caso o una oferta laboral.

Etapa 2

En base a la validación del usuario, al agente se le entregan los casos que fueron realmente definidos como positivos, nuestros y pesimistas, en formato raw.

Etapa 3

El sistema generará un conjunto de buenas practicas por cada uno de los niveles, lo cual es inyectado al agente cada vez que necesita evaluar una oferta.

Etapa 3,5

Se hace un fine-tuning de un conjunto de datos, etiquetados por los humanos, y las ofertas. Se genera un modelo especializado en scores.