DuocUC

Ingeniería de soluciones con AI

Semestre 2026-2

Docente:

Francisco Macaya

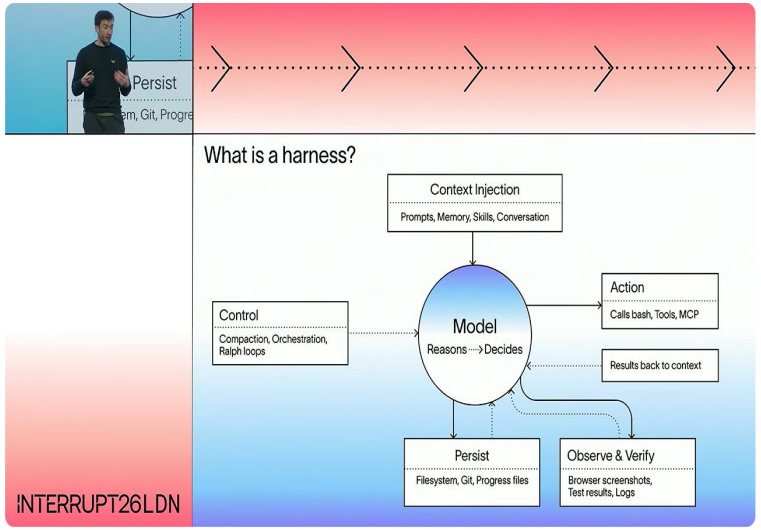
Noticias: *How to Build Agents That Improve Over Time: Model, Harness, Context | Interrupt London*

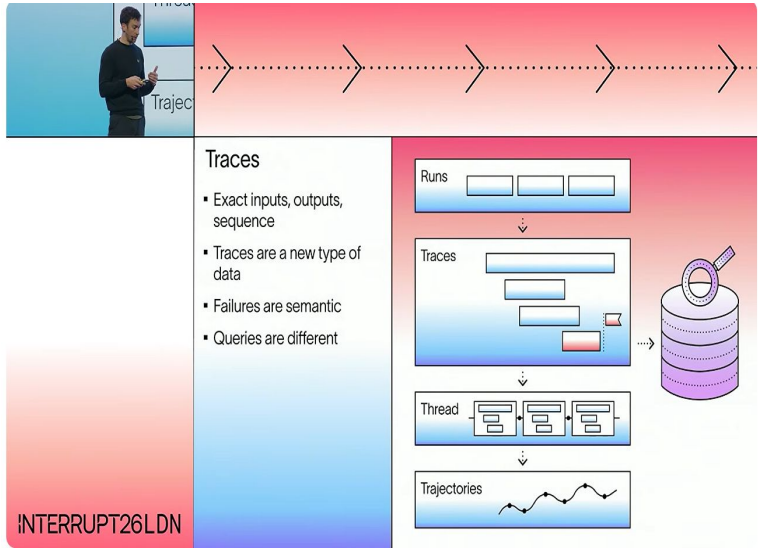


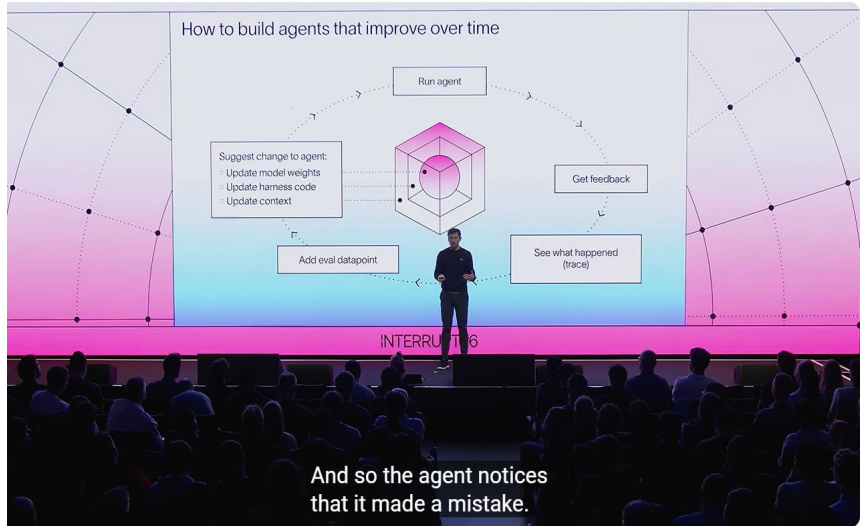
How to Build Agents That Improve Over Time: Model, Harness, Context | Interrupt London

Nota: *https://www.youtube.com/watch?v=xy_7SzwsIjM&t=437s*

Noticias: *How to Build Agents That Improve Over Time: Model, Harness, Context | Interrupt London*







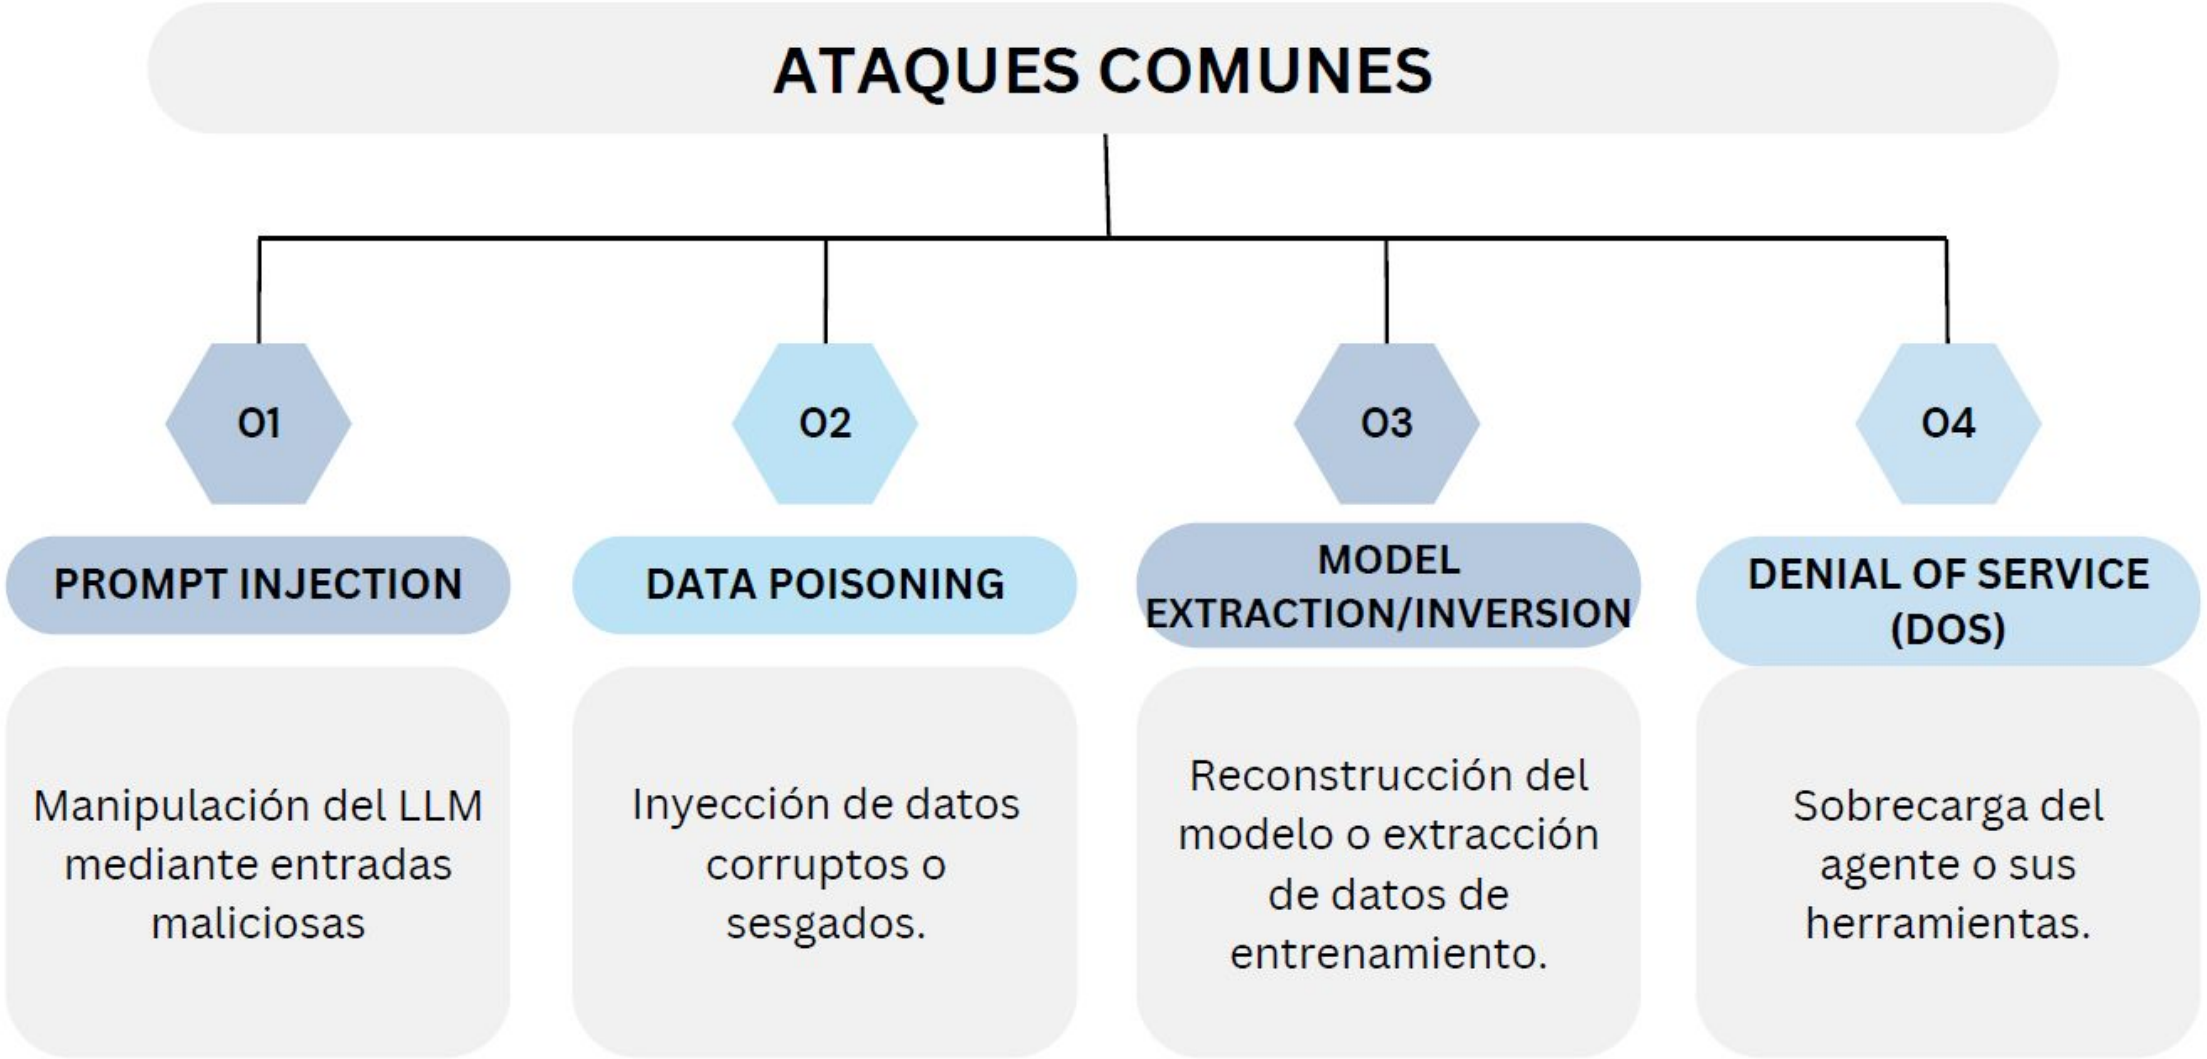
Nota: *https://www.youtube.com/watch?v=xy_7SzwsIjM&t=437s*

¿Por qué es relevante la seguridad?



*La **seguridad** es el piso mínimo de un diseño, no es un característica*

Ataques comunes de AI.

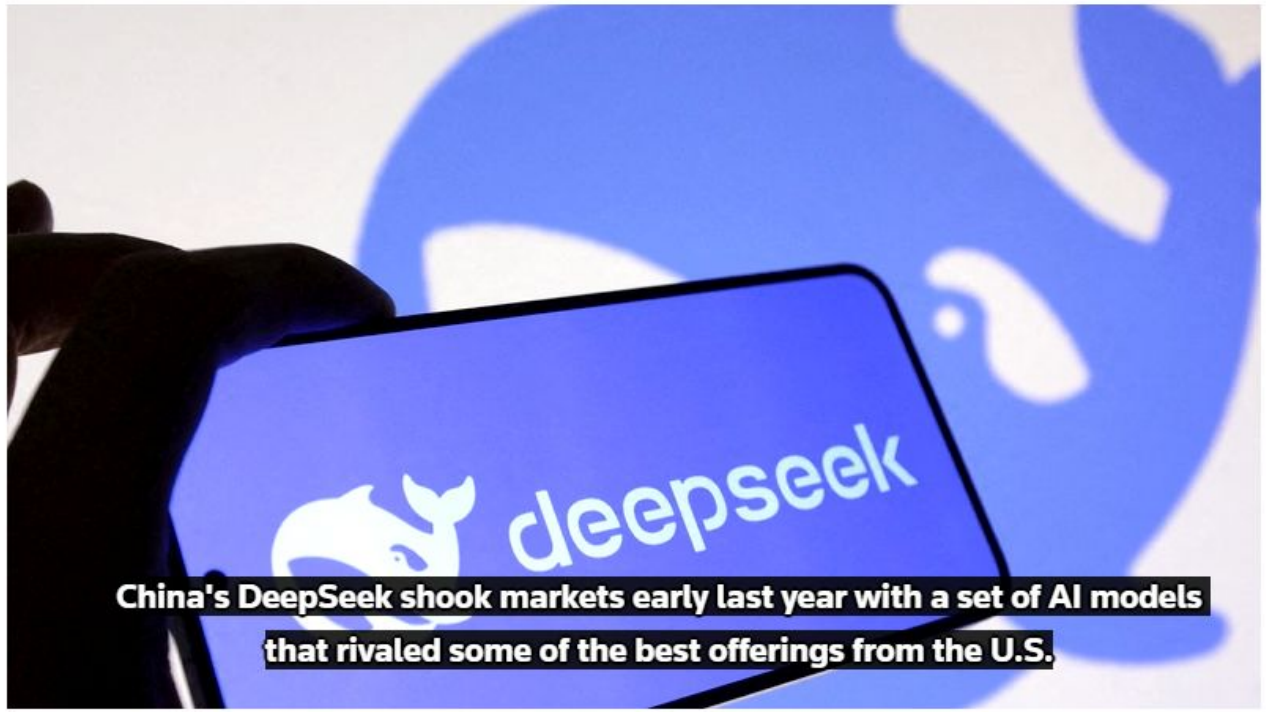


Deep Seek: *¿Cómo inicialmente fueron tan baratos?*

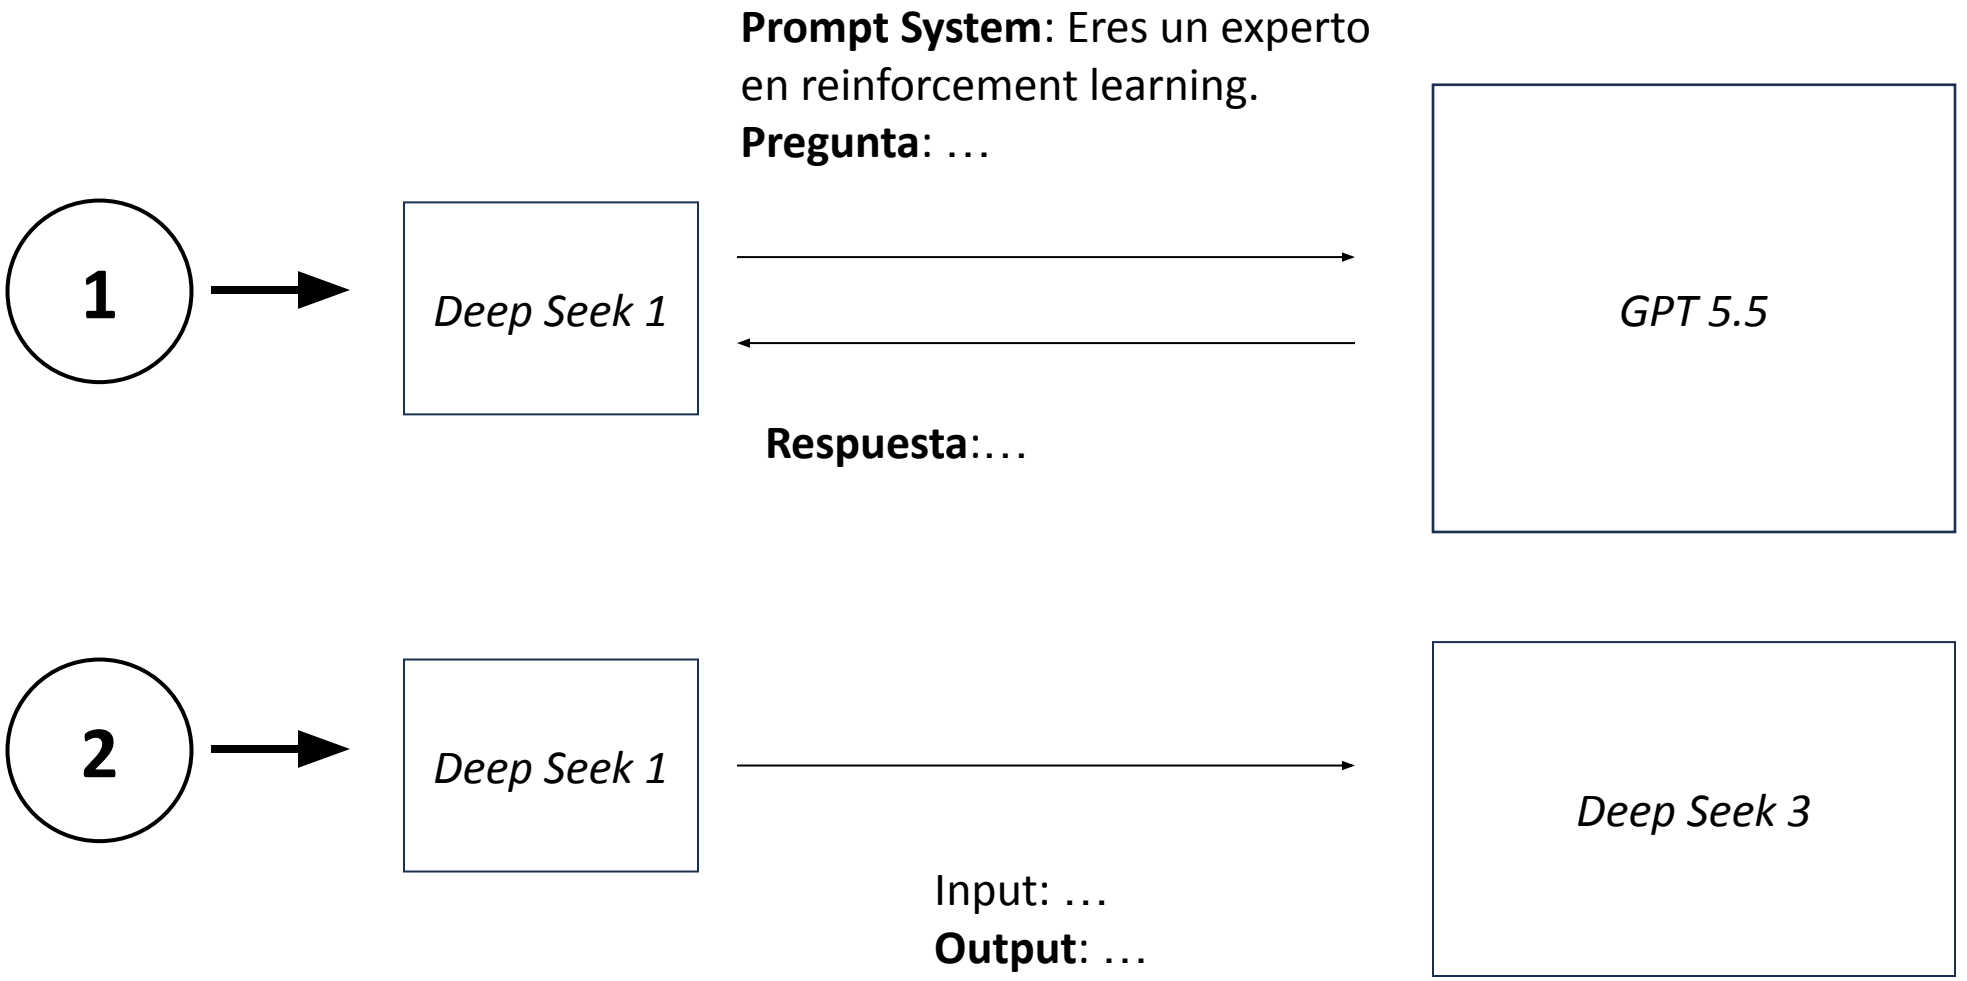
OpenAI says China's DeepSeek trained its AI by distilling US models, memo shows

By **Deepa Seetharaman** and **Fabiola Arámburo**

February 12, 2026 10:16 PM GMT · Updated February 13, 2026



Destilación (Distillation): *Aprende de los mayores.*



Mucho más barato que entrenar un modelo con millones de parámetros. Deep Seek crearon miles de cuentas de OpenAI para entrenar su propio modelo.

Guardrails: *Protege tu sistema ante filtraciones.*

Inputs Guardrails

Las dos principales fugas que evitan son:

1. filtrar información privada a API externas.
2. ejecutar mensajes maliciosos que comprometen su sistema

¿Cómo puede pasar?:

1. Un empleado copia información confidencial de la empresa o información privada de un usuario en un mensaje y la envía a una API de terceros.¹.
2. Un desarrollador de aplicaciones introduce políticas y datos internos de la empresa en el mensaje del sistema de la aplicación.
3. Una herramienta recupera información privada de una base de datos interna y la agrega al contexto.

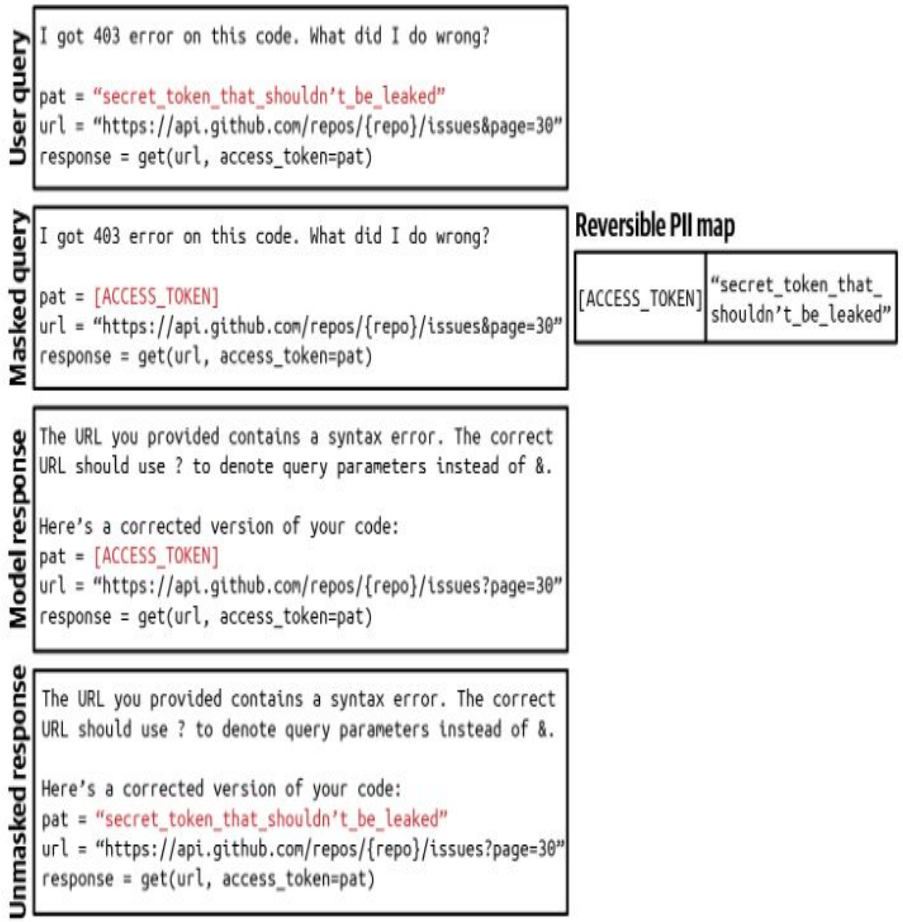


Figure 10-3. An example of masking and unmasking PII information using a reverse PII map to avoid sending it to external APIs.

Guardrails: *Protege tu sistema ante filtraciones.*

Entrada	Riesgo	Estrategia
Consultas del usuario	Inyección de prompts directa	Filtrar patrones sospechosos, límites de longitud y formato, clasificador de intención
Resultados del retrieval	Documentos envene-nados	Sanitizar el corpus al indexar, validar cada fragmento recuperado, separación de contextos
Datos de herramientas externas	APIs que devuelven datos alterados	Esquemas estrictos para las respuestas de las tools
Prompts com-puestos	Mezcla de contexto confiable y externo	System prompt blindado; el contenido externo va en bloques marcados como datos
Mensajes entre agentes	Instrucciones implíci-tas de otros LLM	Validar en cada handoff; cada nodo valida lo que recibe

Guardrails: *Protege tu sistema ante filtraciones.*

Output Guardrails

Sus funciones son:

1. Detectar fallos de salida.
2. Especificar la política para gestionar los diferentes modos de fallo.

- Quality
  - Malformatted responses that don't follow the expected output format. For example, the application expects JSON, and the model generates invalid JSON.
  - Factually inconsistent responses hallucinated by the model.
  - Generally bad responses. For example, you ask the model to write an essay, and that essay is just bad.
- Security
  - Toxic responses that contain racist content, sexual content, or illegal activities.
  - Responses that contain private and sensitive information.
  - Responses that trigger remote tool and code execution.
  - Brand-risk responses that mischaracterize your company or your competitors.

Guardrails: *Protege tu sistema ante filtraciones.*



Figura 11-3. Los tres riesgos de una salida sin sanitizar y el pipeline de cuatro pasos que los contiene.

¿Cómo implementarlo?

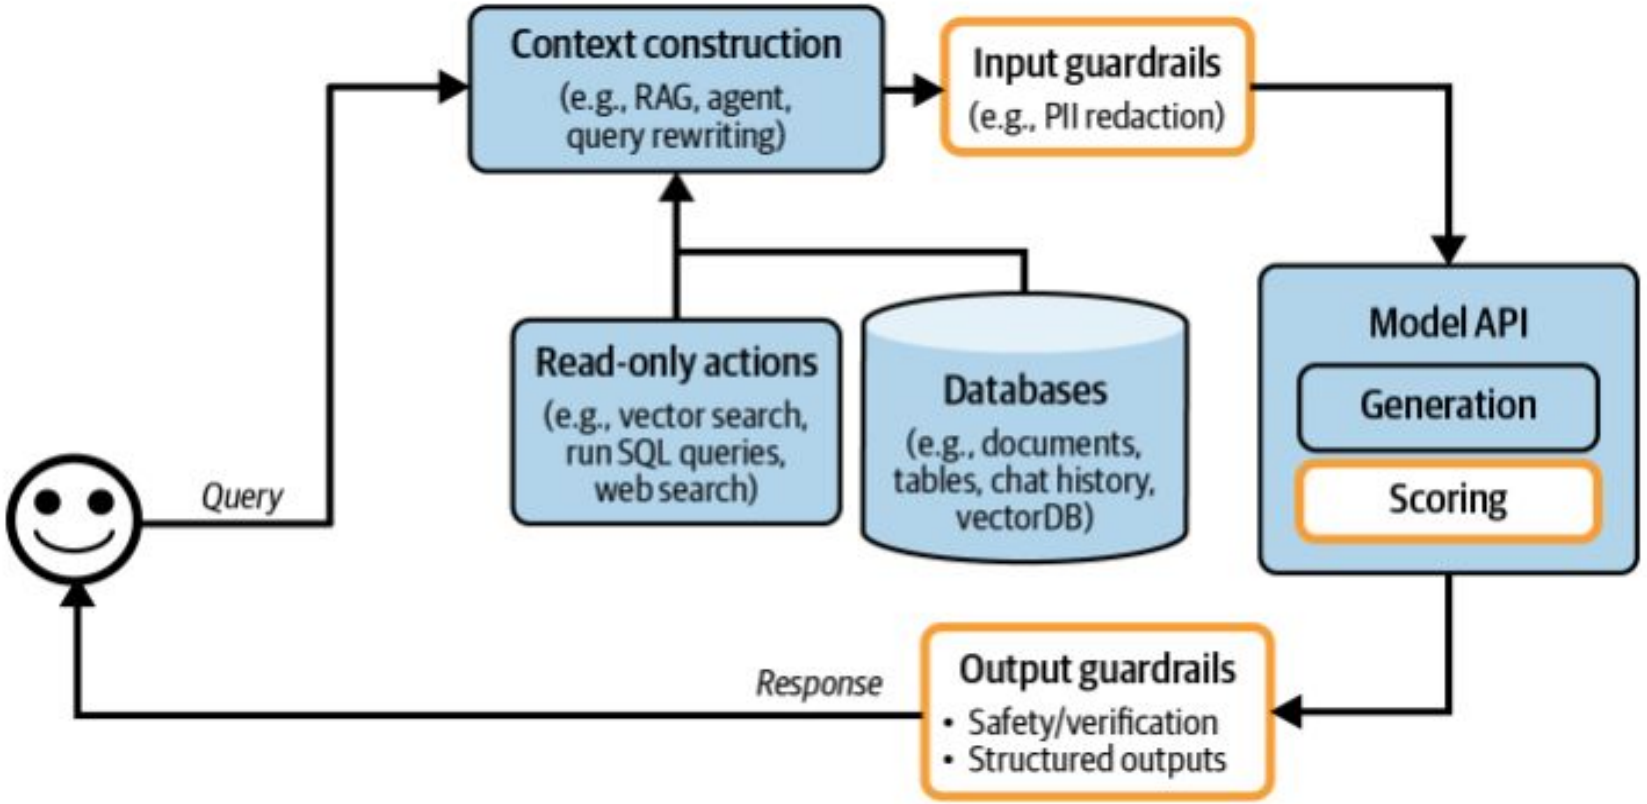


Figure 10-4. Application architecture with the addition of input and output guardrails.

*Sistema protegido, con **input y output guardrails** para resolver cualquier problema de filtraciones y seguridad.*

Éticas y Seguridad: *La AI es una herramienta, no el fin.*

